

Evaluierung von Bias und Fairness in aktuellen Text-zu-Bild-Modellen

Christian Fabian

Zusammenfassung—Moderne Text-zu-Bild-Modelle (T2I) erzielen durch neue Architekturen wie Multimodal Diffusion Transformer (MMDiT) und Flow Matching eine hohe Bildqualität. Dieser Fortschritt bringt jedoch gesellschaftliche und technische Herausforderungen mit sich, vor allem beim Thema Bias und Fairness. Diese Arbeit vergleicht systematisch, wie stark geokulturelle Trainingsdaten westlicher (SD 3.5, FLUX.2) und asiatischer Modelle (Qwen-Image, Z-Image) die visuelle Darstellung von Identitäten prägen. Zudem erfordert die lokale Ausführung großer Modelle (bis zu 32 Mrd. Parameter) oft eine 4-Bit-Quantisierung. Es wird analysiert, ob diese Hardware-Einschränkungen einen sogenannten Mode Collapse begünstigen und Minderheiten dadurch noch seltener repräsentiert werden. Für eine objektive Auswertung der generierten Bilder kommt eine eigens entwickelte, automatisierte Pipeline zum Einsatz, die auf Multimodal Large Language Models (MLLMs) als unabhängige Evaluatoren setzt.

I. EINLEITUNG

Text-zu-Bild-Modelle (T2I) erzeugen dank grundlegender Architekturen wie Latent Diffusion [1] und neuen Technologien wie Multimodal Diffusion Transformern (MMDiT) sowie Flow Matching ([2]) fotorealistische Bilder. Deren großflächiger Einsatz birgt jedoch das Risiko, historische und gesellschaftliche Vorurteile (Bias) aus den Trainingsdaten ungefiltert zu reproduzieren ([3], [4], [5], [6]). So werden statusbehaftete Rollen (CEO, Arzt) überwiegend als weiße Männer, Pflegekräfte (Prompt: Nurse) hingegen fast ausschließlich weiblich generiert ([5], [7]). Trainieren zukünftige Modellgenerationen wiederum auf diesen einseitigen, synthetischen Bildern, droht eine selbstverstärkende Rückkopplungsschleife, die die visuelle Vielfalt durch einen *Mode Collapse* dauerhaft einschränkt ([8]).

Zudem erfordern aktuelle Modelle mit 20 bis 32 Milliarden Parametern (wie FLUX.2 oder Qwen-Image) für den lokalen Einsatz starke Kompressionsverfahren. Welche Folgen eine solche 4-Bit-Quantisierung für die Fairness der KI hat und ob Minderheiten dadurch noch seltener repräsentiert werden, ist bislang kaum untersucht. Da die Forschung bisher fast ausschließlich westliche Daten fokussierte, fehlt außerdem das Wissen darüber, wie asiatische T2I-Systeme die Bildgenerierung kulturell prägen.

Diese Arbeit schließt diese Lücken durch einen Vergleich westlicher (SD 3.5, FLUX.2) und asiatischer Modelle (Qwen-Image, Z-Image). Zentral ist die Frage, wie stark sich der demografische Bias zwischen diesen Kulturräumen unterscheidet und ob die Hardware-Quantisierung diesen Effekt verstärkt. Zur Evaluierung von Ethnizität und Geschlecht greift diese Arbeit auf aktuelle MLLM-as-a-Judge-Ansätze zurück ([9], [10]). Um die Robustheit der Messung zu erhöhen, werden

diese Ansätze hier zu einer neuartigen Pipeline auf Basis eines Multi-MLLM-Ensembles erweitert (Code und Daten: github.com/Chrissey/t2i-models-bias).

II. THEORETISCHE GRUNDLAGEN

Dass sich demografische Verzerrungen in aktuellen Text-zu-Bild-Modellen (T2I) so stark verfestigen, hängt auch mit deren technischer Architektur zusammen. Diese Systeme bestehen primär aus einem Text-Encoder (wie CLIP [11] oder T5 [12]) zur Vektorisierung von Prompts und einem generativen Backbone. Während frühere Generationen auf U-Nets basierten, dominieren heute *Multimodal Diffusion Transformer* (MMDiTs) [2], [13]. Der damit einhergehende Wandel der Mathematik und der Architekturen beeinflusst direkt, wie flexibel Modelle Identitäten generieren können.

A. Definition von Bias und Fairness in der generativen KI

Ferrara (2023) [14] definiert Bias in algorithmischen Systemen als systematische Abweichung von einem fairen Referenzwert. Bei T2I-Modellen tritt dies in zwei Hauptformen auf [15], [16]. Der *Historical Bias* spiegelt tief verwurzelte gesellschaftliche Ungleichheiten wider (z. B. die Assoziation von Führungspositionen mit weißen Männern). Der *Representation Bias* entsteht schlicht durch die ungleiche Verteilung demografischer Merkmale in den Trainingsdaten. Fairness beschreibt folglich das Ziel, diese festgefahrenen Verzerrungen aufzubrechen, um eine ausgewogene, diverse Repräsentation zu schaffen.

B. Mathematische Evolution: Von DDPM zu Flow Matching

Die Bildgenerierung hat sich fundamental gewandelt. Während klassische Diffusionsmodelle (DDPM) Bilder schrittweise über stochastische Zwischenschritte entzaubern [17], nutzen moderne Architekturen wie FLUX.2 oder SD 3.5 das deterministische *Flow Matching* (*Rectified Flows*) [18], [19]. Statt stochastischer Umwege transformiert ein direktes Vektorfeld die Rauschverteilung geradlinig, was die Bildsynthese erheblich beschleunigt und stabilisiert [20]. Diese Geradlinigkeit birgt jedoch einen entscheidenden Nachteil für die demografische Fairness (siehe Abschnitt V-C5). Bei starker Gewichtung des Text-Prompts rastet der unflexible Rechenpfad schnell in stereotype Muster ein und lässt im weiteren Sampling-Verlauf kaum noch Variationen zu.

III. EXISTIERENDE ARBEITEN

Dass generative KI-Systeme gesellschaftliche Vorurteile reproduzieren, ist in der Literatur bereits umfassend belegt. So

wiesen Bianchi et al. [5] nach, dass T2I-Modelle demografische Stereotypen in Berufen nicht nur spiegeln, sondern sogar aktiv verstärken (*Amplification Bias*). Wan et al. [7] belegen zudem, dass dieses Problem über mehrere Modellgenerationen hinweg bestehen bleibt. Um diesen Bias zu messen, nutzen frühere Studien meist deterministische Computer-Vision-Modelle wie FairFace [21] oder DeepFace [22]. Aktuell geht der Trend in der Forschung jedoch zu sogenannten MLLM-as-a-Judge-Ansätzen [9], [10]. Dabei übernehmen multimodale Sprachmodelle die Bewertung der generierten Bilder. Die Literatur warnt bei textbasierten LLM-Evaluatoren bereits vor einem sogenannten *Self-Preference Bias*, bei dem Modelle eigene Ausgabemuster bevorzugen [23], [24]. Um dieses Risiko auch bei MLLMs zu minimieren, nutzt diese Arbeit ein Modell-Ensemble. Trotz dieser methodischen Fortschritte weist die bisherige Forschung zwei wesentliche Forschungslücken auf. Erstens konzentrieren sich aktuelle Studien fast ausschließlich auf westliche Architekturen und Datensätze [25], [26]. Ein direkter geokultureller Vergleich mit nativ asiatischen Modellen, wie etwa *Qwen-Image* [27] oder *Z-Image* [28], fehlt bislang. Zweitens ignoriert die Forschung weitgehend die sozialen Folgen der Hardware-Kompression. Rein technische Analysen belegen zwar, dass Quantisierungsfehler die Wahrscheinlichkeitsberechnungen in den Modellen verzerren [29]. Es ist jedoch noch unklar, wie sich hochkomprimierte 4-Bit-Modelle bei alltäglichen Aufgaben auf lokalen Rechnern verhalten. Insbesondere fehlt die Erkenntnis, ob diese deutliche Hardware-Einschränkung einen vorzeitigen *Mode Collapse* [8] auslöst und somit die visuelle Vielfalt zerstört. Um beide Fragen zu beantworten, wurde die im folgenden Abschnitt beschriebene Pipeline entwickelt.

IV. METHODIK UND EXPERIMENTELLER AUFBAU

Da bestehende Datensätze die mehrdimensionalen Variablen dieser Arbeit (geokultureller Vergleich, Hardware-Quantisierung und architektonische CFG-Ablation) nicht abdecken, wurde ein kontrolliertes *Behavioral Testing* durchgeführt, für das alle Bilder selbst generiert wurden. Die dafür entwickelte automatisierte End-to-End-Pipeline (Abb. 1) bestand aus einer deterministischen Bildgenerierung (fest definierte Seeds), einer Gesichtserkennung auf Basis von YOLOv11 [30] sowie einer Klassifizierung durch ein Multi-MLLM-Ensemble.

Insgesamt wurden 892 Bilder erstellt und analysiert:

- **Hauptdatensatz (Makro-Bias, 630 Bilder):** Mit fünf Modell-Setups (SD 3.5, FLUX.2 Klein, Z-Image in FP16; Qwen-Image, FLUX.2 Dev in 4-Bit) wurden anhand von sechs stereotyp-anfälligen Prompts [5], [7] (z.B. *CEO*, *Nurse*, *Doctor*) über 21 Seeds generiert.
- **Ablationsdatensatz (262 Bilder):** Zur Untersuchung der Auswirkung der CFG-Skalierung auf die Ausgabediversität wurden CFG-Werte (0.0 bis 12.0) variiert [31].
- **Ground-Truth-Stichprobe (150 Bilder aus dem Hauptdatensatz):** Zur Validierung der automatisierten MLLM-Evaluatoren wurden 30 Bilder pro Modell manuell annotiert.

Die Auswertung erfolgte hybrid: Die phänotypischen Merkmale wurden automatisiert via Zero-Shot-Prompting durch das MLLM-Ensemble extrahiert und durch eine DeepFace-Baseline validiert [22]. Zur topologischen Analyse im latenten Raum [32], [33] wurden die Bilder zudem via *CLIP* [11] in Embeddings überführt.

V. ERGEBNISSE

A. KI-Alignment und Validierung der Pipeline

Die Validierung der Pipeline offenbarte eine deutliche methodische Schwäche deterministischer Computer-Vision-Modelle wie *DeepFace*. Diese Inadäquatheit zeigt sich in drei wesentlichen Aspekten: Erstens verfügt das Modell strukturell über keine Kategorien für eine feingranulare Analyse auf der *Monk Skin Tone* (MST) Skala. Zweitens erzwingt es bei Mehrdeutigkeiten konsistent eine harte Einordnung (keine *Unclear*-Kategorie). Drittens lag die Genauigkeit selbst bei der groben Zuordnung von Ethnien mit knapp 58 % spürbar unter der Leistung aktueller multimodaler Modelle. Dies unterstreicht die Tendenz klassischer Modelle zu starren, binären und oft westlich-dominierten Kategorien [21], [34]. Daher stützt sich unsere Evaluation primär auf das Multi-MLLM-Ensemble (Qwen2.5-VL [35], InternVL3.5 [36], Gemma4:e4b [37], alle lokal ausgeführt via Ollama). Eine manuell annotierte *Ground-Truth*-Stichprobe ($n = 150$) belegte das Alignment dieser KI-Evaluatoren. Die exakte Übereinstimmungsquote zwischen den einzelnen MLLMs und menschlichen Annotatoren lag bei der Ethnie zwischen 71 – 76 % und beim Geschlecht zwischen 90 – 94 % (Abb. 2). Die feingranulare Zuordnung auf der MST-Skala schlug hingegen auch bei den MLLMs fast vollständig fehl, da ihnen hierfür die spezifische visuelle Kalibrierung fehlt und wechselnde künstliche Lichtverhältnisse in den generierten Bildern eine objektive Bestimmung zusätzlich verfälschen.




Abbildung 2. Globales KI-Alignment: Exakte Übereinstimmungsquote der automatisierten Evaluatoren mit der menschlichen Ground-Truth ($n = 150$).

Wie Abbildung 3 am Beispiel der Geschlechterzuordnung sichtbar macht, sind MLLMs im Gegensatz zu CV-Modellen in der Lage, visuelle Mehrdeutigkeiten zu erkennen (Kategorie *Unclear*). Dass DeepFace hier konsistent fehlerhafte, rein binäre Zuordnungen erzwingt, bestätigt endgültig die Notwendigkeit, sich für differenzierte Bias-Auswertungen von klassischen CV-Baselines abzuwenden.




Abbildung 1. Automatisierte End-to-End Inferenz- und Evaluations-Pipeline.




Abbildung 3. Inter-Rater-Reliabilität (Beispiel SD 3.5). Während MLLMs Mehrdeutigkeiten erkennen (Kategorie *Unclear*), erzwingt DeepFace konsistent eine fehlerhafte binäre Zuordnung.

B. Demografischer Makro-Bias: Der universelle Gender-Bias

Nachdem die Auswertungsmethodik validiert war, lag der Fokus auf der Analyse des Hauptdatensatzes ($n = 630$). Es ging nun darum, die Repräsentationsstarrheit der Modelle konkret in Zahlen zu fassen. Um sicherzugehen, dass keine einzelnen Fehlurteile der KI-Evaluatoren das Bild verzerren, wurden ausschließlich die Mehrheitsentscheide (*Majority Vote*) der drei MLLMs herangezogen. Die Auswertung ist eindeutig: Jedes getestete Modell zeigt einen klaren geschlechts-spezifischen Bias.

Bereits bei den Basis-Architekturen in FP16-Präzision (siehe Tabelle I) fielen die Generierungen fast durchgehend in traditionelle Geschlechterrollen zurück. Am stärksten äußerte sich dieser *Mode Collapse* bei den Prompts „CEO“ und „Nurse“. Den CEO stellten die Modelle fast nur männlich dar, während der Begriff „Nurse“ fast ausschließlich zu weiblichen Gesichtern führte. Ähnliche Verzerrungen bei administrativen und medizinischen Berufen wurden bereits in früheren Studien belegt [5], [38].

Noch extremer wirkte sich dieser Effekt aus, wenn die Hardware limitierte. Die 4-Bit-Kompression verstärkte die vorhandenen Stereotypen zusätzlich zu einer absoluten Starrheit. Am

Tabelle I

DOMINANTE GESCHLECHTERVERTEILUNG NACH MODELL UND PROMPT (M = MAN, W = WOMAN). WERTE UNTER 100 % WERDEN DURCH DIE KATEGORIE *Unclear* ODER DAS GEGENGESCHLECHT ERGÄNZT.

Modell	Beautiful	CEO	Nurse	Doctor	Cleaner	Poor
FLUX.2 Klein	100 % W	100 % M	100 % W	100 % M	40 % W	78 % M
Z-Image	95 % W	95 % M	100 % W	65 % M	48 % W	46 % W
SD 3.5	95 % W	90 % M	100 % W	76 % M	32 % M	52 % M

Beispiel des quantisierten FLUX-Modells wird dieser *Mode Collapse* in Abbildung 4 deutlich: Hier liegt die Stereotypisierung nicht mehr nur bei bestimmten Berufen vor, sondern erstreckt sich über *ausnahmslos alle sechs* getesteten Prompts hinweg bei exakt 100 %. Auch das asiatische 4-Bit-Modell Qwen-Image bestätigte diesen extremen Trend mit einer fast ebenso absoluten Einfärbung (aufgrund von Platzrestriktionen hier nicht tabellarisch aufgeführt).




Abbildung 4. Ausgeprägter Mode Collapse am Beispiel des Modells FLUX: Die generierte Geschlechterverteilung zeigt eine 100 %-ige Stereotypisierung bei Prompts wie „CEO“, „Doctor“ und „Nurse“.

Ein struktureller *Historical Bias* [15] ist also nicht nur in den Parametern verankert, sondern wird durch die Datenkompression zusätzlich verfestigt. Das hebt den von Bianchi et al. beschriebenen *Amplification Bias* [5], [7] im lokalen Einsatz auf ein noch höheres Niveau. Forscher wie Seshadri et al. [39] warnen zwar davor, eine gemessene Amplifikation vorschnell

überzubewerten, da sie oft nur ein Artefakt aus der Diskrepanz zwischen Trainingsdaten und Test-Prompts sei. Der hier dokumentierte Kollaps ist aber über mehrere unabhängige Modelle und Prompts hinweg reproduzierbar und liefert damit einen soliden empirischen Beleg. Das deutet klar darauf hin, dass es sich hierbei nicht nur um einen methodischen Ausreißer handelt.

C. Geokultureller Shift und phänotypische Divergenz

Der Gender-Bias bleibt kulturübergreifend stabil. Bei den Ethnien sieht das anders aus; hier dominiert eine geokulturelle Verschiebung. Aus welchen Daten aktuelle T2I-Modelle genau lernen, halten die Hersteller zwar zunehmend geheim. Doch das Standardverhalten der KIs bei der Generierung von Gesichtern verrät, aus welchen Regionen und Kulturen ihre Web-Scrapes stammen könnten [25], [26]. Dieses Muster zeigt sich sowohl bei den unkomprimierten FP16-Modellen als auch bei den 4-Bit-quantisierten Varianten.

1) *FP16-Basismodelle: Kulturelle Dominanz und geokulturelle Polarisierung*: Ein direkter Vergleich der vollpräzisen Modelle (siehe Tabelle II) macht diese geokulturelle Polarisierung sofort sichtbar. Westlich geprägte Modelle wie SD 3.5 neigen bei statusbehafteten Berufen stark zu kaukasischen (*White*) Gesichtern [4], [5]. So generiert SD 3.5 auf den Prompt „Nurse“ zu rund 87 % und beim Prompt „CEO“ zu knapp 81 % weiße Personen. FLUX.2 Klein folgt zwar einem ähnlichen westlichen Grundmuster, zeigt aber beim „CEO“ bereits eine Abweichung (~48 % *White* / ~33 % *Asian*). Das deutet darauf hin, dass hier mit einer etwas breiteren und diverseren Datenbasis trainiert wurde.

Das nativ asiatische Modell Z-Image zeigt hingegen eine gegenläufige Tendenz. Es weist einen erkennbaren *Representation Bias* zugunsten asiatischer Phänotypen auf (Nurse: ~90 % *Asian*, CEO: ~57 % *Asian*).

Bemerkenswert sind auch die mit einem Sternchen (*) markierten Prompts in der Tabelle. Hier waren sich die drei MLLM-Evaluatoren stark uneinig, was auf eine hohe *Annotator-Divergenz* hindeutet. Beim Prompt „Poor“ konnten die Evaluatoren beispielsweise bei keinem der drei FP16-Modelle einen stabilen Konsens erzielen (vgl. „Chaos“ bei FLUX.2 Klein in Tabelle II). Das passt zum allgemeinen Befund, dass Mehrheitsentscheide bei subjektiven Aufgaben echte Meinungsverschiedenheiten verdecken [40]. Im Fall visueller, kulturell geprägter Konzepte wie sozialem Status wird diese Unschärfe vermutlich noch größer [25].

Tabelle II

DOMINANTE ETHNIEN: FP16-VOLLPRÄZISIONSMODELLE NACH PROMPT (KONSENS DER MLLMS). STERNCHEN (*) MARKIEREN PROMPTS MIT STARKER ANNOTATOR-DIVERGENZ (STARKE UNEINIGKEIT DER EVALUATOREN).

Prompt	FLUX.2 Klein 9B (West)	SD 3.5 Large (West)	Z-Image (Ost)
Beautiful	~68 % <i>White</i> *	~52 % <i>Black</i> *	~66 % <i>Asian</i>
CEO	~48 % <i>White</i> / 33 % <i>Asian</i> *	~81 % <i>White</i>	~57 % <i>Asian</i>
Doctor	~49 % <i>White</i> *	~61 % <i>White</i>	~61 % <i>Asian</i>
Nurse	~87 % <i>White</i>	~87 % <i>White</i>	~90 % <i>Asian</i>
Poor	Chaos (kein Konsens) *	~46 % <i>Black</i> / <i>Indian</i> *	~49 % <i>Asian</i> / 37 % <i>Indian</i> *
Cleaner	~68 % <i>White</i> / 30 % <i>Unclear</i>	~50 % <i>Unclear</i> / 20 % <i>Asian</i> *	~40 % <i>Asian</i> / 30 % <i>White</i> *

2) *4-Bit-quantisierte Modelle: Verfestigung und die Stock-Foto-Anomalie*: Bei den 4-Bit-quantisierten Modellen setzt sich diese Tendenz fort. Die geokulturelle Prägung bleibt nicht nur erhalten, sie zementiert sich in vielen Fällen weiter (vgl. Tabelle III). Damit greift dieselbe Amplifikationsdynamik, die schon beim Gender-Bias zu beobachten war (siehe Abschnitt V-B). FLUX.2 Dev kollabiert beispielsweise beim Prompt „CEO“ auf rund 90 % weiße Gesichter. Das verfestigt die westliche Prägung noch einmal deutlich stärker als das ebenfalls westliche FP16-Modell FLUX.2 Klein (das nur auf ~48 % *White* / 33 % *Asian* kam). An dieser Stelle ist jedoch methodische Vorsicht geboten. Dieser deutliche Unterschied lässt sich nicht isoliert als reiner Quantisierungseffekt interpretieren. Er ist vielmehr auch auf die unterschiedlichen Modellarchitekturen und Trainingsgrundlagen von Dev und Klein zurückzuführen.

Eine Ausnahme bildet Qwen-Image. Bei neutralen Prompts bevorzugt dieses Modell durchgehend asiatische Phänotypen (Beautiful: ~85 % *Asian*, CEO: ~80 % *Asian*). Beim Prompt „Doctor“ ändert sich dieses Verhalten jedoch signifikant, das Modell beschränkt sich auf 98 % kaukasische Ärzte. Dieser plötzliche Phänotyp-Wechsel zeigt eine auffällig einheitliche, an *Stock-Foto-Klischees* erinnernde Bildästhetik. Da die Bilddatenbanken im Internet strukturell stark westlich dominiert sind [4], überschreibt der domänenspezifische Berufsbias der medizinischen Stock-Fotografie die eigentliche geokulturelle Grundprägung des Modells [33], [38].

Auch beim Prompt „Poor“ zeigt Qwen-Image mit ~80 % weißen Gesichtern ein unerwartetes Muster, was auf eine stark westlich geprägte Foto-Ästhetik für das Konzept „Armut“ hindeuten könnte [25].

Tabelle III

DOMINANTE ETHNIEN DER 4-BIT-QUANTISIERTEN MODELLE NACH PROMPT (KONSENS DER MLLMS). STERNCHEN (*) MARKIEREN PROMPTS MIT STARKER ANNOTATOR-DIVERGENZ (STARKE UNEINIGKEIT DER EVALUATOREN).

Prompt	FLUX.2 Dev (4-Bit/West)	Qwen-Image (4-Bit/Ost)
Beautiful	Split: ~51 % <i>White</i> / 43 % <i>Asian</i>	~85 % <i>Asian</i>
CEO	~90 % <i>White</i>	~80 % <i>Asian</i>
Doctor	~57 % <i>White</i> * (Rest: Chaos)	~98 % <i>White</i>
Nurse	~70 % <i>Asian</i> / 30 % <i>White</i>	Chaos (~44 % <i>W</i> / 31 % <i>A</i>) *
Poor	~48 % <i>Asian</i> / 43 % <i>Indian</i> *	~80 % <i>White</i> *
Cleaner	~98 % <i>White</i>	Split: ~62 % <i>White</i> / 35 % <i>Asian</i>

3) *MLLM-Annotator-Divergenz: Die Subjektivität von Ethnie*: Trotz der generellen Übereinstimmung beim Geschlecht zeigte die Inter-Rater-Reliabilität bei subjektiveren Konstrukten wie der Ethnizität deutliche Abweichungen. Während das Geschlecht von den KI-Evaluatoren zuverlässig erkannt wurde, wick das MLLM-Ensemble bei ambivalenten Prompts wie „Poor“ oder „Cleaner“ stark voneinander ab (vgl. Tab. II und III).

Dabei offenbarte sich vereinzelt *Lone-Wolf-Verhalten*: Je nach Prompt wich ein einzelnes MLLM, wie beispielsweise InternVL in Abbildung 5, systematisch von den anderen Modellen ab. Dies belegt, dass MLLMs identische Bilder

phänotypisch stark unterschiedlich interpretieren (sogenannte *Annotator-Divergenz*) und zu eigenwilligen Klassifizierungen neigen. Einen rein objektiven, neutralen Beobachter gibt es hier nicht.

Da Ethnizität keine objektiv messbare Kategorie, sondern ein subjektives Konstrukt ist [34], liefern isolierte Evaluierungsmodelle hier zwangsläufig verzerrte Metriken. Dies untermauert zwingend die Notwendigkeit des gewählten Multi-MLLM-Ansatzes mit Mehrheitsentscheid (*Majority Vote*), um modellspezifische Klassifikationstendenzen und individuelle Unschärfen einzelner KI-Evaluatoren methodisch auszugleichen.




Abbildung 5. Phänotypische Divergenz (*Annotator-Divergenz*) beim Evaluieren identischer Bilder. Die abweichenden Balkenhöhen zwischen Gemma4, InternVL3.5 und Qwen2.5-VL belegen, dass die KI-gestützte Klassifizierung von Ethnie stark subjektiv und modellabhängig ist.

4) *Topologische Starrheit im latenten Vektorraum*: Die bisherigen Ergebnisse stützten sich auf die textbasierte Auswertung der MLLMs. Um den Bias zusätzlich auf einer rein geometrischen Ebene zu verifizieren, wurden CLIP-Embeddings [11] der Bilder erstellt und mittels UMAP in einen 2D-Raum projiziert. So lässt sich die topologische Struktur der Repräsentationsräume visuell auswerten [33]. In Abbildung 6 bilden sich sechs klar voneinander getrennte Hauptcluster, die exakt den sechs Prompt-Themen entsprechen.

Interessant wird es jedoch innerhalb dieser Cluster. Hier lässt sich eine klare systematische Divergenz zwischen den Modellen erkennen. Die generierten Bilder von FLUX.2 Klein sammeln sich tendenziell im „White“- und „Indian“-Bereich. Die Bilder von Z-Image wandern im exakt selben Prompt-Cluster dagegen stark in den „Asian“-Bereich ab. Die Punktwolken zeigen: Der Text-Prompt gibt zwar das grobe Hauptcluster vor, doch die geokulturelle Prägung des Modells diktiert die feinkörnige ethnische Trennung im Inneren. Das bestätigt die bisherigen Befunde noch einmal auf einer rein mathematisch-geometrischen Ebene, unabhängig von der Subjektivität einzelner KI-Evaluatoren.

Um diese optischen Eindrücke messbar zu machen, fasst Tabelle IV die Silhouette Scores [32] aller Modelle zusammen. Hier gilt: Ein höherer Score steht für dichtere, schärfer voneinander abgetrennte Cluster und somit für eine starrere, stärker stereotype Bildgenerierung [41]. Ein niedriger Score weist hingegen auf fließendere Übergänge und diversere Repräsentationen hin.

Das nativ asiatische Z-Image erreicht mit 0.30 den niedrigsten Wert und untermauert damit seine vergleichsweise große visuelle Vielfalt. FLUX.2 Klein liegt mit 0.55 bereits deutlich höher. Interessant ist die Analyse der 4-Bit-Quantisierung: Unter Hardware-Kompression steigen die Werte weiter in die Höhe (FLUX.2: 0.65, Qwen-Image: 0.60). Dies deutet darauf hin, dass die Datenkompression die Stereotypen weiter verfestigt (vgl. die methodische Einschränkung zu Architektur-Konfundierungen im vorherigen Abschnitt). Dennoch stützt diese Beobachtung bisherige Studien, die zeigen, dass Quantisierungsfehler Wahrscheinlichkeitsverteilungen verzerren [29]. Wie genau das Modellverhalten architektonisch gesteuert wird, wird im nachfolgenden Abschnitt V-C5 im Detail diskutiert.




Abbildung 6. UMAP-Projektion der CLIP-Embeddings (FP16-Modelle): FLUX.2 Klein (Kreise) vs. Z-Image (Kreuze), eingefärbt nach MLLM-klassifizierter Ethnie (InternVL3.5-8B). Innerhalb jedes Prompt-Clusters liegen FLUX.2-Punkte überwiegend im „White“-/„Indian“-Bereich, während Z-Image-Punkte im selben Cluster stärker zu „Asian“ tendieren.

Tabelle IV
SILHOUETTE SCORES IM CLIP-UMAP-RAUM NACH MODELL UND PRÄZISION.

Modell	Präzision	Silhouette Score
Z-Image	FP16	0.30
SD 3.5	FP16	0.44
FLUX.2 Klein	FP16	0.55
Qwen-Image	4-Bit	0.60
FLUX.2	4-Bit	0.65

5) *Architektonische Dynamik unter CFG-Skalierung*: Die sogenannte Classifier-Free-Guidance-Skala (CFG) [31] steuert, wie strikt sich ein Modell bei der Bildgenerierung an den vorgegebenen Text-Prompt halten muss. Welche Auswirkungen dieser Parameter auf den Bias hat, veranschaulicht die Ablationsstudie in Abbildung 7.

Bei einer sehr niedrigen CFG-Skala (≤ 1.0) ist die motivische Ausprägung teilweise noch instabil oder weniger spezifisch. Erreicht der Wert jedoch die Marke von etwa 2.5, rastet das Modell rasch ein und geht in ein stabiles, stereotypes Muster über (der sogenannte *Mode Collapse*). Treibt man die Steuerung sehr weit in die Höhe (CFG 12.0), führt diese Übersteuerung teilweise zu deutlichen visuellen

Artefakten oder sogar zur starken Zerstörung der Bildstruktur, gut erkennbar am Beispiel von SD 3.5 in der oberen Reihe.

Dieses Verhalten legt nahe, dass der geokulturelle Bias kein Zufallsprodukt ist. Vielmehr wirkt er wie ein Attraktor im latenten Raum. Sobald die Steuerung durch den Text-Prompt stark genug gewichtet wird, konvergiert das Modell mit hoher Wahrscheinlichkeit zu diesem Stereotyp. In der reinen Mathematik ist dieser Trade-off zwischen exakter Prompt-Befolgung (*Prompt-Fidelity*) und der Vielfalt der generierten Bilder bereits bekannt [31]. Die hier vorliegenden Ergebnisse übertragen dieses technische Prinzip nun jedoch empirisch auf eine soziokulturelle Ebene.




Abbildung 7. CFG-Ablationsstudie: Prompt „prof_doctor“ (Seed 101), Modelle SD 3.5 (oben) und Z-Image (unten). Mit steigender CFG-Skala (links nach rechts) kollabiert SD 3.5 von einem instabilen Zustand zu einem stabilen, stereotypen Phänotyp und degeneriert bei CFG 12.0 weitgehend, während Z-Image durchgehend stabil bleibt und seine eigene geokulturelle Prägung beibehält.

VI. DISKUSSION

A. Kritische Einordnung der Methodik

Wie in Abschnitt V-C3 gezeigt, existiert aufgrund modellspezifischer Bias-Muster bei der Bewertung komplexer Konstrukte keine absolute Neutralität [34]. Abbildung 2 veranschaulicht diese Subjektivität deutlich. Während das Geschlecht zuverlässig erkannt wird, fällt die Übereinstimmung bei der Ethnizität spürbar ab. Dies ist weniger eine methodische Schwäche als vielmehr Ausdruck der belegten *Annotator-Divergenz* [40]. Dieselbe Abbildung zeigt zudem das fast vollständige Scheitern der Evaluatoren bei der *Monk Skin Tone* (MST) Skala, da den Modellen die sichere Kalibrierung für solch nuancierte Hautton-Abstufungen schlicht fehlt.

Eine weitere methodische Limitation stellt die durchgehend englische Prompt-Sprache dar. Da Englisch als dominante Prompt-Sprache fungiert, dürfte dies im latenten Raum der Modelle zusätzlich die Aktivierung westlicher Konzepte und Ästhetiken verstärken, eine generelle geokulturelle Dominanz, die in der Literatur bereits umfangreich belegt ist [26]. Aus diesem Grund wurde die tatsächliche kulturelle Eigenprägung der östlichen Modelle in dieser Studie potenziell sogar noch unterschätzt.

B. Interpretation der Modellmechanik

Die in Abschnitt V-C5 diskutierten Ergebnisse verdeutlichen ein grundlegendes Prinzip: Der beobachtete *Mode Collapse* ist keine fehlerhafte oder böswillige „Entscheidung“ des Modells [6], [14]. Stattdessen generieren die Modelle lediglich statistische Wahrscheinlichkeiten, die ausschließlich auf der historischen Häufigkeitsverteilung ihrer Trainingsdaten basieren [16].

Die so erzeugten Bilder repräsentieren also keine echten menschlichen Identitäten, sondern vielmehr mathematische Wahrscheinlichkeitsmaxima im latenten Raum. Ebenso wenig erkennen die MLLMs bei ihrer anschließenden Evaluation reale Personen; sie klassifizieren letztlich nur synthetische, statistisch errechnete Pixel-Muster. Das relativiert zwar die Vorstellung einer bewussten Diskriminierung, entlastet die Entwickler aber nicht von der Verantwortung für die reproduzierten Verzerrungen.

VII. FAZIT UND AUSBLICK

A. Zusammenfassung der Kernbefunde

Ziel dieser Arbeit war ein struktureller Vergleich aktueller Text-zu-Bild-Architekturen. Im Fokus stand die Frage, wie sich der demografische Bias zwischen westlichen und asiatischen Modellen unterscheidet, insbesondere dann, wenn Hardware-Restriktionen ins Spiel kommen. Die Auswertung liefert drei zentrale Erkenntnisse.

Über alle Modelle hinweg existiert zunächst ein konsistenter Gender-Bias, der in einen *Mode Collapse* von über 90 % mündet. Bei den Ethnien zeigt sich dagegen ein anderes Bild. Dort dominiert eine starke geokulturelle Prägung: Westliche Modelle generieren standardmäßig weiße, östliche Modelle asiatische Phänotypen. Diese Grundregel wird jedoch bei westlich geprägten Statussymbolen durch eine an „Stock-Foto-Klischees“ erinnernde Ästhetik deutlich durchbrochen: So generiert das asiatische Qwen-Image zu 98 % weiße Ärzte.

Auch die Hardware-Architektur spielt eine Rolle. Komprimiert man Modelle für den lokalen Einsatz per 4-Bit-Quantisierung, zementieren sich bestehende Stereotypen weiter. Wie in Abschnitt V-C5 gezeigt, konvergieren die Repräsentationen dabei unausweichlich zu stereotypen Mustern. Dies ist ein Effekt, der sich unter Kompression weiter zu verfestigen scheint (vgl. methodische Einschränkungen zur Konfundierung im Ergebnisteil).

Methodisch zeigt sich, dass KI-Evaluatoren bei subjektiven Konzepten stark abweichen (*MLLM-Annotator-Divergenz*), was die Bewertung durch Einzelmodelle problematisch macht. Um verzerrte Metriken zu vermeiden, sind Multi-MLLM-Pipelines sinnvoll, kombiniert mit einer menschlichen Kontroll-Instanz (*Human-in-the-Loop*).

B. Ausblick und Limitationen

Aus diesen Erkenntnissen ergeben sich folgende methodische und architektonische Implikationen. Methodisch müssen spezielle Multi-MLLM-Analyse-Tools zum Standard werden. Auf architektonischer Ebene sind *Debiasing*-Techniken unerlässlich, die direkt tief im latenten Raum ansetzen. Zudem muss sich auch die Datengrundlage ändern: Die Entwicklung von bewusst divers kuratierten, sogenannten „Bias-Aware“-Trainingsdatensätzen erscheint wichtig.

Die zunehmende Nutzung KI-generierter Bilder als Trainingsmaterial birgt zudem das Risiko einer *Model Autophagy Disorder* (MAD) [8]. In dieser synthetischen Endlosschleife würden sich die hier dokumentierten Bias-Muster in zukünftigen KI-Iterationen noch weiter verstärken.

REFERENZEN

- [1] R. Rombach, A. Blattmann, D. Lorenz, P. Esser und B. Ommer, *High-Resolution Image Synthesis with Latent Diffusion Models*, 2022. arXiv: 2112.10752 [cs.CV]. Adresse: <https://arxiv.org/abs/2112.10752>.
- [2] P. Esser u. a., *Scaling Rectified Flow Transformers for High-Resolution Image Synthesis*, 2024. arXiv: 2403.03206 [cs.CV]. Adresse: <https://arxiv.org/abs/2403.03206>.
- [3] R. Naik und B. Nushi, *Social Biases through the Text-to-Image Generation Lens*, 2023. arXiv: 2304.06034 [cs.CY]. Adresse: <https://arxiv.org/abs/2304.06034>.
- [4] A. Birhane, V. U. Prabhu und E. Kahembwe, *Multimodal datasets: misogyny, pornography, and malignant stereotypes*, 2021. arXiv: 2110.01963 [cs.CY]. Adresse: <https://arxiv.org/abs/2110.01963>.
- [5] F. Bianchi u. a., „Easily Accessible Text-to-Image Generation Amplifies Demographic Stereotypes at Large Scale“, in *2023 ACM Conference on Fairness, Accountability, and Transparency*, Ser. FAccT '23, ACM, 2023, S. 1493–1504. DOI: 10.1145/3593013.3594095. Adresse: <http://dx.doi.org/10.1145/3593013.3594095>.
- [6] A. Katirai, N. Garcia, K. Ide, Y. Nakashima und A. Kishimoto, „Situating the social issues of image generation models in the model life cycle: a sociotechnical approach“, *AI and Ethics*, Jg. 5, Nr. 2, S. 1769–1786, 2024, ISSN: 2730-5961. DOI: 10.1007/s43681-024-00517-3. Adresse: <http://dx.doi.org/10.1007/s43681-024-00517-3>.
- [7] Y. Wan u. a., *Survey of Bias In Text-to-Image Generation: Definition, Evaluation, and Mitigation*, 2024. arXiv: 2404.01030 [cs.CV]. Adresse: <https://arxiv.org/abs/2404.01030>.
- [8] S. Alemohammad u. a., *Self-Consuming Generative Models Go MAD*, 2023. arXiv: 2307.01850 [cs.LG]. Adresse: <https://arxiv.org/abs/2307.01850>.
- [9] L. Gierbach, S. Alaniz, G. Smith und Z. Akata, *A Large Scale Analysis of Gender Biases in Text-to-Image Generative Models*, 2025. arXiv: 2503.23398 [cs.CV]. Adresse: <https://arxiv.org/abs/2503.23398>.
- [10] A. Chinchure u. a., *TIBET: Identifying and Evaluating Biases in Text-to-Image Generative Models*, 2024. arXiv: 2312.01261 [cs.CV]. Adresse: <https://arxiv.org/abs/2312.01261>.
- [11] A. Radford u. a., *Learning Transferable Visual Models From Natural Language Supervision*, 2021. arXiv: 2103.00020 [cs.CV]. Adresse: <https://arxiv.org/abs/2103.00020>.
- [12] C. Raffel u. a., *Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer*, 2023. arXiv: 1910.10683 [cs.LG]. Adresse: <https://arxiv.org/abs/1910.10683>.
- [13] W. Peebles und S. Xie, *Scalable Diffusion Models with Transformers*, 2023. arXiv: 2212.09748 [cs.CV]. Adresse: <https://arxiv.org/abs/2212.09748>.
- [14] E. Ferrara, „Fairness and Bias in Artificial Intelligence: A Brief Survey of Sources, Impacts, and Mitigation Strategies“, *Sci*, Jg. 6, Nr. 1, S. 3, Dez. 2023, ISSN: 2413-4155. DOI: 10.3390/sci6010003. Adresse: <http://dx.doi.org/10.3390/sci6010003>.
- [15] H. Suresh und J. Gutttag, „A Framework for Understanding Sources of Harm throughout the Machine Learning Life Cycle“, in *Equity and Access in Algorithms, Mechanisms, and Optimization*, Ser. EAAMO '21, ACM, Okt. 2021, S. 1–9. DOI: 10.1145/3465416.3483305. Adresse: <http://dx.doi.org/10.1145/3465416.3483305>.
- [16] N. Mehrabi, F. Morstatter, N. Saxena, K. Lerman und A. Galstyan, *A Survey on Bias and Fairness in Machine Learning*, 2022. arXiv: 1908.09635 [cs.LG]. Adresse: <https://arxiv.org/abs/1908.09635>.
- [17] J. Ho, A. Jain und P. Abbeel, *Denoising Diffusion Probabilistic Models*, 2020. arXiv: 2006.11239 [cs.LG]. Adresse: <https://arxiv.org/abs/2006.11239>.
- [18] Y. Lipman, R. T. Q. Chen, H. Ben-Hamu, M. Nickel und M. Le, *Flow Matching for Generative Modeling*, 2023. arXiv: 2210.02747 [cs.LG]. Adresse: <https://arxiv.org/abs/2210.02747>.
- [19] X. Liu, C. Gong und Q. Liu, *Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow*, 2022. arXiv: 2209.03003 [cs.LG]. Adresse: <https://arxiv.org/abs/2209.03003>.
- [20] S. Gupta und Y. Taiwade, *Efficiency vs. Fidelity: A Comparative Analysis of Diffusion Probabilistic Models and Flow Matching on Low-Resource Hardware*, 2025. arXiv: 2511.19379 [cs.LG]. Adresse: <https://arxiv.org/abs/2511.19379>.
- [21] K. Kärkkäinen und J. Joo, *FairFace: Face Attribute Dataset for Balanced Race, Gender, and Age*, 2019. arXiv: 1908.04913 [cs.CV]. Adresse: <https://arxiv.org/abs/1908.04913>.
- [22] S. I. Serengil und A. Ozpinar, „Boosted LightFace: A Hybrid DNN and GBM Model for Boosted Facial Recognition“, *Gazi University Journal of Science*, Jg. 39, Nr. 1, S. 452–466, 2026. DOI: 10.35378/gujs.1794891. Adresse: <https://dergipark.org.tr/en/pub/gujs/article/1794891>.
- [23] K. Wataoka, T. Takahashi und R. Ri, *Self-Preference Bias in LLM-as-a-Judge*, 2025. arXiv: 2410.21819 [cs.CL]. Adresse: <https://arxiv.org/abs/2410.21819>.
- [24] R. Dominguez-Olmedo, M. Hardt und C. Mendler-Dünner, *Questioning the Survey Responses of Large Language Models*, 2024. arXiv: 2306.07951 [cs.CL]. Adresse: <https://arxiv.org/abs/2306.07951>.
- [25] H. Seo u. a., *Exposing Blindspots: Cultural Bias Evaluation in Generative Image Models*, 2026. arXiv: 2510.20042 [cs.CV]. Adresse: <https://arxiv.org/abs/2510.20042>.
- [26] Z. Bayramli u. a., *Diffusion Models Through a Global Lens: Are They Culturally Inclusive?*, 2025. arXiv: 2502.08914 [cs.CV]. Adresse: <https://arxiv.org/abs/2502.08914>.

- [27] C. Wu u. a., *Qwen-Image Technical Report*, 2025. arXiv: 2508.02324 [cs.CV]. Adresse: <https://arxiv.org/abs/2508.02324>.
- [28] I. Team u. a., *Z-Image: An Efficient Image Generation Foundation Model with Single-Stream Diffusion Transformer*, 2026. arXiv: 2511.22699 [cs.CV]. Adresse: <https://arxiv.org/abs/2511.22699>.
- [29] Y. He, L. Liu, J. Liu, W. Wu, H. Zhou und B. Zhuang, *PTQD: Accurate Post-Training Quantization for Diffusion Models*, 2023. arXiv: 2305.10657 [cs.CV]. Adresse: <https://arxiv.org/abs/2305.10657>.
- [30] R. Khanam und M. Hussain, *YOLOv11: An Overview of the Key Architectural Enhancements*, Code: <https://github.com/ultralytics/ultralytics>, abgerufen am 01.07.2026, 2024. arXiv: 2410.17725 [cs.CV]. Adresse: <https://arxiv.org/abs/2410.17725>.
- [31] J. Ho und T. Salimans, *Classifier-Free Diffusion Guidance*, 2022. arXiv: 2207.12598 [cs.LG]. Adresse: <https://arxiv.org/abs/2207.12598>.
- [32] P. J. Rousseeuw, „Silhouettes: A graphical aid to the interpretation and validation of cluster analysis“, *Journal of Computational and Applied Mathematics*, Jg. 20, S. 53–65, 1987, ISSN: 0377-0427. DOI: [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7). Adresse: <https://www.sciencedirect.com/science/article/pii/0377042787901257>.
- [33] A. S. Luccioni, C. Akiki, M. Mitchell und Y. Jernite, *Stable Bias: Analyzing Societal Representations in Diffusion Models*, 2023. arXiv: 2303.11408 [cs.CY]. Adresse: <https://arxiv.org/abs/2303.11408>.
- [34] M. K. Scheuerman, K. Wade, C. Lustig und J. R. Brubaker, „How We’ve Taught Algorithms to See Identity: Constructing Race and Gender in Image Databases for Facial Analysis“, *Proc. ACM Hum.-Comput. Interact.*, Jg. 4, Nr. CSCW1, Mai 2020. DOI: 10.1145/3392866. Adresse: <https://doi.org/10.1145/3392866>.
- [35] S. Bai u. a., *Qwen2.5-VL Technical Report*, 2025. arXiv: 2502.13923 [cs.CV]. Adresse: <https://arxiv.org/abs/2502.13923>.
- [36] W. Wang u. a., *InternVL3.5: Advancing Open-Source Multimodal Models in Versatility, Reasoning, and Efficiency*, 2025. arXiv: 2508.18265 [cs.CV]. Adresse: <https://arxiv.org/abs/2508.18265>.
- [37] Google DeepMind, *Gemma 4 Model Card*, <https://deepmind.google/models/gemma/gemma-4/>, Zugegriffen: 1. Juli 2026, 2026. Adresse: https://ai.google.dev/gemma/docs/core/model_card_4?hl=de.
- [38] F. Vandewiele, R. Synave, S. Delepoulle und R. Cozot, *Beyond the Prompt: Gender Bias in Text-to-Image Models, with a Case Study on Hospital Professions*, 2025. arXiv: 2510.00045 [cs.CV]. Adresse: <https://arxiv.org/abs/2510.00045>.
- [39] P. Seshadri, S. Singh und Y. Elazar, *The Bias Amplification Paradox in Text-to-Image Generation*, 2023. arXiv: 2308.00755 [cs.LG]. Adresse: <https://arxiv.org/abs/2308.00755>.
- [40] A. M. Davani, M. Díaz und V. Prabhakaran, *Dealing with Disagreements: Looking Beyond the Majority Vote in Subjective Annotations*, 2021. arXiv: 2110.05719 [cs.CL]. Adresse: <https://arxiv.org/abs/2110.05719>.
- [41] K. S. Vardhana, S. Lolla und S. Biswas, *Fully Unsupervised Self-debiasing of Text-to-Image Diffusion Models*, 2025. arXiv: 2512.03749 [cs.CV]. Adresse: <https://arxiv.org/abs/2512.03749>.

ERKLÄRUNG ZUR NUTZUNG VON KI-HILFSMITTELN

Gemäß den universitären Richtlinien wurde für die Erstellung dieser Arbeit ein LLM unterstützend herangezogen. Die Nutzung beschränkte sich strikt auf zwei klar voneinander getrennte Bereiche. Die vollständigen, unredigierten Chatverläufe sind als Nachweis unter den folgenden Links einsehbar:

- **Struktur und Logik:** Brainstorming zur Kapitelstruktur, Theorie-Aufbau und Diskussion zur logischen Platzierung und check recherchierter Quellen.
Nachweis: <https://share.gemini.google/QbGV0wwfCuwm>
- **Wissenschaftliches Lektorat:** Überprüfung der verfassten Rohtexte auf Rechtschreibung, Grammatik, Zeichensetzung und akademischen Stil (Sentence Polishing) ohne inhaltliche Textgenerierung.
Nachweis: <https://claude.ai/share/dd887078-63f5-4d31-b1d1-337135bcac2a>

Alle inhaltlichen Argumente, die Interpretation der Daten sowie die finale Texterstellung entstammen ausnahmslos der intellektuellen Eigenleistung des Autors.

Code: <https://github.com/Chrissey/t2i-models-bias>