


EVALUIERUNG VON BIAS UND FAIRNESS IN AKTUELLEN TEXT-ZU-BILD-MODELLEN

Ein Vergleich von SD 3.5, Flux.2 (West) vs. Qwen-Image, Z-Image (Ost)



Gliederung



Was fällt euch auf?

CEO



NURSE



SE




DRUG DEALER



Generiert mit Stable Diffusion 3.5 Large, Prompt: „A photo of a ...“

Gesellschaftliche Relevanz



Generative KI ist heutzutage überall.
Mainstream


Was ist Bias in der KI?

Bias Definition:

Eine systematische und konsistente Abweichung der Ausgabe eines Algorithmus von einem Referenzwert, der in der Abwesenheit von Vorurteilen als fair erwartet werden würde.

↓
Bias
entsteht

Ferrara, E. (2023).



Bildquelle: H. Suresh & J. Gutttag (2021).

Bias Effekt?

Repräsentations-Bias (Unterrepräsentation):

Bestimmte demografische Gruppen (z. B. Ethnien, Altersgruppen) fehlen in den generierten Ergebnissen völlig.

- Class Bias
- Racial/Ethnic Bias

Stereotypen-Bias (Fehlrepräsentation):

Gruppen werden ausschließlich in stark klischeebehafteten oder abwertenden Rollen gezeigt.

- Gender Bias
- Cultural Bias

Disparate Impact:

Beschreibt die unbeabsichtigte, aber systematische Benachteiligung bestimmter Gruppen durch scheinbar neutrale KI-Prozesse.

- Cultural Bias
- Racial Bias

Forschungsfrage

Hauptfrage:

Ein struktureller Vergleich aktueller Text-zu-Bild-Architekturen:
Wie unterscheiden sich westliche und asiatische Modelle
hinsichtlich ihres **demografischen Bias** (unter lokalen Hardware-
Restriktionen?)

Teilziel 1:

Der kulturelle
Vergleich
(West vs. Ost)



Teilziel 2:

Der Einfluss
lokaler Hardware-
Grenzen

Teilziel 3:

Architektur-Einflüsse
(MMDiT)


Die Entwicklung von T2I-Modellen



Das Diffusions-Prinzip

Das Konzept:

Diffusionsmodelle lernen, Bilder aus purem Zufallsrauschen (Gaussian Noise) zu generieren, indem sie einen zweistufigen Prozess durchlaufen



Denoising Diffusion Probabilistic Models (DDPM)

Forward Process:

(Vorwärtsprozess, Daten verrauschen):

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\alpha_t}x_0, (1 - \alpha_t)I)$$

Forward Shortcut:

$$x_t = \sqrt{\alpha_t} \cdot x_0 + \sqrt{1 - \alpha_t} \cdot \epsilon$$


Reverse Process:

Das Modell (ϵ_θ) lernt, das exakte Rauschen (ϵ) vorherzusagen und zu entfernen.

$$\mathcal{L}_{simple} = \mathbb{E}_{t, x_0, \epsilon, c} [||\epsilon - \epsilon_\theta(x_t, t, c)||^2]$$

Das Bias-Problem:

Diffusion lernt rein statistische Wahrscheinlichkeiten aus den Trainingsdaten. Das Modell reproduziert den Durchschnitt aus Milliarden Bildern.



Iterative Denoising Step:

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \widehat{\epsilon}_{\theta}(x_t, t, c) \right) + \sigma_t z$$

Bild Generierung

Faktor "c" (Conditioning):

Text-Encoder übersetzen Prompts in mathematische Vektoren.

Gesteuertes Entrauschen:

Das Modell säubert das Bild nicht blind, sondern wird vom Text-Vektor gelenkt.

Die Bias-Falle:

Text-Modelle (wie CLIP, T5) lernen Semantik aus Milliarden ungefilterten Web-Daten.

Text-Encoder Bias (CLIP / T5) + Diffusions-Bias (Mode Collapse)

Rausch-Vorhersage durch **Classifier-Free**


Guidance CFG (w) verstärkt wird

$$\widehat{\epsilon}_{\theta} = \epsilon_{\theta}(x_t, t, \emptyset) + w \cdot (\epsilon_{\theta}(x_t, t, c) - \epsilon_{\theta}(x_t, t, \emptyset))$$


= Ohne Text+CFG-Wert*(Mit Text–Ohne Text)

Die Mathematik: Flow Matching/Rectified Flow


Konzept: Das Modell kratzt kein Rauschen mehr ab, sondern zieht eine gerade Linie von Rauschen (x_0) zu Bild (x_1). (berechnet einen Vektorfluss.)
Model lernt die Geschwindigkeit/Richtung (v) direkt zum Zielbild.




(a) Data.




(b) Path design.



(c) Training.



(d) Sampling.



(b) Diffusion

Iterativer Schritt:

$$x_{t+\Delta t} = x_t + \Delta t \cdot \widehat{v}_\theta(x_t, t, c)$$

Lern-Formel:

$$L_{CFM} = \mathbb{E}_{t, x_0, x_1, c} \left[\|v_\theta(x_t, t, c) - (x_1 - x_0)\|^2 \right]$$

Lineare Shortcut:

$$x_t = (1 - t) \cdot x_0 + t \cdot x_1$$

Classifier-Free Guidance (CFG)

$$\begin{aligned} & \tilde{v} \\ &= v_{uncond} + w \\ & \cdot (v_{cond} - v_{uncond}) \end{aligned}$$

Die Trainingsdaten

Westliche Modelle: FLUX.2 & SD 3.5

Daten-Philosophie: Vage Transparenz & "Web-Scale" Daten.

Stable Diffusion 3.5: Offiziell trainiert auf "*filtered publicly available data*" und "*synthetic data*".

FLUX.2: Proprietäre Blackbox. Black Forest Labs hält die genaue Zusammensetzung der Datensätze komplett geheim.

Bias-Entstehung: Passiv. Spiegelung der Internet-Stereotypen & westlicher Ästhetik

Asiatische Modelle: Qwen, Z-Image

Daten-Philosophie: Radikale, KI-gesteuerte Kuration.

Qwen-Image: Milliarden Bilder, die durch das hauseigene VLM (Qwen2.5-VL) neu annotiert und nach Qualität gefiltert wurden


Z-Image: Nutzung einer *Active Curation Engine* und eines *World Knowledge Topological Graph*, um Wissen aktiv zu strukturieren.

Bias-Entstehung: Systematisch. Das steuernde Sprachmodell (LLM) fungiert als kultureller Filter und prägt dem Bildmodell sein Weltverständnis auf.

Ein Text-zu-Bild-Modell ist ein statistischer Spiegel seiner Daten.


Esser et al. (2024), Bianchi et al (2023), Qwen Team (2025), Z-Image Team (2025), Greenberg (2025)

Die Evolution Paradigmenwechsel (Architektur)




Stable Diffusion 3.5 (Stability AI)

- **Modellgrößen:** Large (8.1B Parameter) & Medium (2.5B)
- **Model type:** MMDiT (Multimodal Diffusion Transformer) text-to-image generative model
- **Text (c) und Bild (x):** eigene Verarbeitungsspuren, die sich nur zur Abstimmung (Attention) treffen
- **Text Encoders:**
 - CLIPs: OpenCLIP-ViT/G, CLIP-ViT/L
 - T5: T5-xxl
- **Mathematik:** Nutzt Flow Matching (Rectified Flow) statt klassischer Diffusion.
- **QK Normalization:** Trainingsstabilität




(a) Overview of all components.



(b) One *MM-DiT* block


Flux.2 (Black Forest Labs)

- **Modellgröße:**
Flux.1 12B -> Flux.2 32B
- **VLM statt reiner Text-Encoder:**
Statt CLIP und T5 jetzt Mistral-Small-3.1 (Mistral-3 24B)
- **Architektur-Shift:**
Mehr Single-Stream-Blöcken 48 und weniger Double-Stream Blöcke 8
- **Maximale Qualität:**
Einen von Grund auf neu trainierten latenten Raum (neuer VAE) und native 4-Megapixel-Auflösung





Qwen-Image (2512)

- **Modellgröße:** 28B (20B MMDiT und VLM + VAE 8B)
- **Encoder:** Qwen2.5 VL
- **Basis:** Klassischer Double-Stream MMDiT
- **MS-RoPE:** (Multimodal Scalable Rotary Positional Encoding)
- **Trainingsdaten:** Komplexe Pipeline
- Kann Bilder bearbeiten
- Enhanced Human Realism



Z-Image (Tongyi-MAI)

- **Modellgröße:** 7B
- **Architektur:** Scalable Single-Stream Multi-Modal Diffusion Transformer (S3-DiT)
- Qwen3-4B VLM
- Flux VAE Decoder
- 3D Unified RoPE um mit Stream umzugehen
- Reinforcement Learning with Human Feedback (RLHF)



Das Hardware-Problem für SOTA-Modelle

FP32 (Unmöglich):
4 Bytes/Param. →
FLUX.2 braucht 128
GB VRAM. (Keine
Hardware verfügbar).

FP16 (Standard):
2 Bytes/Param. →
FLUX.2 braucht 64 GB
VRAM. (Nur für
Server/Workstations).

FP8 (8-bit): 1
Byte/Param. → FLUX.2
braucht ~32-40 GB
VRAM. (Benötigt 48
GB Profi-GPUs oder
Multi-GPU-Setups).

Rettung:

4-bit Quantisierung (bnb NF4 / GGUF):
~0.7 Bytes/Param. → FLUX.2 braucht **~20 GB**
VRAM.

Die Gefahr: Zerstört dieser massive
Datenverlust die kulturelle Vielfalt des Modells?

Wie wird Bias gemessen?

**Prompt
Erstellung**

Standard-Ansatz:
neutrale Prompts

Human Evaluation

$$R_f(p) = \frac{|F(p)|}{|F(p)| + |M(p)|}$$


Automatisierte
Klassifikation

Zuordnung

Welche Art von Bias?

Auswertung

Gesellschaftliche Relevanz



Generative KI ist heutzutage überall.
Mainstream

Integration in den Alltag



Introducing Claude Design by Anthropic Labs

17. Apr. 2026

KI PowerPoint-Präsentationsgenerator

Erstellen Sie in wenigen Minuten professionelle PowerPoint-Präsentationen mit einem KI-Präsentationsgenerator.

Copilot erkunden

PowerPoint öffnen

Comfy

ComfyUI Official Documentation



The most powerful open source node-based application for generative AI

Fi

Adobe Firefly. Create like never before.


It's never been easier to bring your ideas to life. Generate and edit images, video, audio, and designs using top AI models from Adobe, Google, OpenAI, and more.

SEPTEMBER 25, 2025

FLUX.1 Kontext now in Adobe Photoshop: Powering Every...

By pairing Photoshop's professional editing environment with FLUX.1 Kontext [Pro]'s accuracy...

[Read more](#)




Introducing Canva's AI Image Generators

With Canva's AI image generators, the perfect image is always at your fingertips—even if it doesn't exist yet. With **Magic Media™** and **Create an image**, powered by **Dream Lab**, you can quickly visualize ideas, sketch out creative concepts, or push the limits of what's possible. Watch your words transform into beautiful images you can use on your [presentations](#), [social media](#) posts, and other creative projects.

Generate AI Images


Das "Hidden Prompt" Problem



Open AI (2023), Wan et al. (2024), Yang et al. (2025), Bianchi et al. (2023)

Zukünftige Modelle ?

Wird nicht der Bias stärker, wenn mehr KI-Bilder ins Netz kommen?



- **Model Autophagy Disorder (MAD):** Die KI trainiert auf ihren eigenen synthetischen Daten.
- **Model Collapse:** Degenerativer Prozess. Die "Ränder" der Datenverteilung (Diversität) sterben aus, der Mainstream zementiert sich.
- **Lösung:** Synthetische Daten können aber auch helfen (gezielte "Diversity Injection").


Teaser?

EINGABE: 6 NEUTRALE PROMPTS



BILDGENERIERUNG

MODELL-ARCHITEKTUREN & VARIATIONEN



20-30 BILDER
PRO PROMPT,

PRO KI


AUSGABE: KLASSIFIZIERTE
BILDDATENSÄTZE



Sortable: Miniature,
classifiziertes image
datasetensätze, sorted by
prompt type and model

ANALYSE & EVALUIERUNG

AUTOMATISIERTE KLASSIFIZIERUNG



GENDER BIAS ANALYSIS

$$Rf(p) = \frac{|F(p)|}{|F(p)| + |M(p)|}$$

MENSCHLICHE EVALUIERUNG

Manuelle Kreuzprüfung &
Annotation auf Stichprobensätzen
(e.g., n=3000 insgesamt)

VERGLEICHENDE BIAS-
ANALYSE & AUSBLICK

Fragen?



Quellen

- *The state of AI in early 2024 (McKinsey Report)* <https://www.mckinsey.com/capabilities/quantumblack/our-insights/the-state-of-ai-2024>
- *Easily Accessible Text-to-Image Generation Amplifies Demographic Stereotypes at Large Scale (Bianchi et al., 2023)* <https://arxiv.org/pdf/2211.03759>
- *Diffusion Models: A Comprehensive Survey of Methods and Applications* (Yang et al., 2023) <https://arxiv.org/pdf/2209.00796>
- *A Framework for Understanding Sources of Harm throughout the Machine Learning Life Cycle (H. Suresh & J. Gutttag (2021))* <https://arxiv.org/abs/1901.10002>
- *Fairness And Bias in Artificial Intelligence: A Brief Survey of Sources, Impacts, And Mitigation Strategies (Ferrara, E. (2023))* <https://arxiv.org/abs/2304.07683>
- *Wan et al. (2024). "Survey of Bias In Text-to-Image Generation".* <https://arxiv.org/abs/2404.01030>
- *A Large Scale Analysis of Gender Biases in Text-to-Image Generative Models* (Girrbach et al. (2025)) <https://arxiv.org/abs/2503.23398>
- *Jiang, R., Zheng, G., Li, T., Yang, T., Wang, J., & Li, X. (2024): A Survey of Multimodal Controllable Diffusion Models. Journal of Computer Science and Technology, 39, 509–541.* <https://dl.acm.org/doi/10.1007/s11390-024-3814-0> (Jiang et al.)
- *Ho, J., Jain, A., & Abbeel, P. (2020). Denoising Diffusion Probabilistic Models (DDPM)* <https://arxiv.org/abs/2006.11239>
- *Rombach et al. (2022). High-Resolution Image Synthesis with Latent Diffusion Models.* <https://arxiv.org/abs/2112.10752>
- *Text-to-Image: Diffusion, Text Conditioning, Guidance, Latent Space (2023).* <https://eugeneyan.com/writing/text-to-image/>
- *Schuhmann et al. (2021/2022). LAION-400M / LAION-5B* <https://arxiv.org/abs/2210.08402>
- *Ho & Salimans (2021). Classifier-Free Diffusion Guidance.* <https://arxiv.org/pdf/2207.12598>
- *Song et al. (2020) Denoising Diffusion Implicit Models* <https://arxiv.org/pdf/2010.02502>
- *Alemohammad et al. (2023) Self-Consuming Generative Models Go MAD* <https://arxiv.org/abs/2307.01850>
- *Chen et al. (2024) Would Deep Generative Models Amplify Bias in Future Models?* <https://arxiv.org/abs/2404.03242>

Quellen

- Mehrabi et al. (2021) A Survey on Bias and Fairness in Machine Learning <https://arxiv.org/pdf/1908.09635>
- Lipman et al. (2022) Flow Matching for Generative Modeling <https://arxiv.org/abs/2210.02747>
- Lipman et al. (2024) Flow Matching Guide and Code <https://arxiv.org/abs/2412.06264>
- Peebles & Xie (2023) Scalable Diffusion Models with Transformers <https://arxiv.org/abs/2212.09748>
- Liu et al. (2022) Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow <https://arxiv.org/abs/2209.03003>
- Qwen Team (2025) Qwen-Image Technical Report <https://arxiv.org/abs/2508.02324>
- Z-Image Team (2025) Z-Image: An Efficient Image Generation Foundation Model with Single-Stream Diffusion Transformer <https://arxiv.org/abs/2511.22699>
- Greenberg Demystifying Flux Architecture <https://arxiv.org/abs/2507.09595>
- Hugging Face (2025). Diffusers welcomes FLUX-2 <https://huggingface.co/blog/flux-2>
- Black Forest Labs (2025). FLUX.2: Frontier Visual Intelligence <https://bfl.ai/blog/flux-2>
- Yang et al. (2025) Text to Image Generation and Editing: A Survey <https://arxiv.org/pdf/2505.02527>
- FLUX.1 Architecture Bild reddit: https://www.reddit.com/r/LocalLLaMA/comments/1ekr7ji/fluxs_architecture_diagram_dont_think_theres_a/
- Kemal Erdem (2023) Step by Step visual introduction to Diffusion Models. <https://erdem.pl/2023/11/step-by-step-visual-introduction-to-diffusion-models>
- Esser et al. (2024) Scaling Rectified Flow Transformers for High-Resolution Image Synthesis <https://arxiv.org/pdf/2403.03206>
- Open AI (2023) DALL E 3 System card https://cdn.openai.com/papers/DALL_E_3_System_Card.pdf

Hinweis

- Die Bilder wurden zum Teil durch Gemini erstellt (Folien: Teaser?, Zukünftige Modelle, Hidden Prompt, Gesellschaftliche Relevanz, Gliederung, Erste Folie (Intro Folie))